

Devoir 1

2025-11-02

Question 3

Le jeu de données sur l’infection des oreilles comporte 287 observations et 4 variables explicatives:

- Swim: nageur fréquent ou pas (Freq ou Occas)
- Loc: nage à la mer ou pas (Beach ou nonBeach)
- Age: âge des nageurs (15-19, 20-24 ou 25-29)
- Sex: sexe des nageurs (Female ou Male)

Statistiques descriptives

En explorant les données, on remarque que toutes les variables explicatives à l’étude sont catégorielles. Les graphiques de ces variables en fonction de la variable réponse Infec montre principalement:

Selon la variable Swim, il y a autant de nageurs ayant eu une infection de l’oreille que ceux n’ayant pas eu d’infection pour les nageurs ayant une fréquence occasionnelle. En revanche, chez ceux qui nagent de façon fréquente, il y a un peu moins de nageurs qui ont eu une infection.

Concernant la localisation (Loc), il y a un peu plus de nageurs qui n’ont pas eu d’infection en nageant ailleurs que dans la mer, tandis que ceux qui nagent dans la mer ont une proportion plus élevée de ne pas avoir d’infection par rapport à ceux ayant eu une infetion.

On remarque qu’il n’y a pas vraiment de différence entre le fait d’avoir ou non une infection selon le sexe, mais une légère distinction apparait pour les femmes pour lesquelles il y a un peu moins de risque d’avoir une infection.

Enfin, il y a également autant de nageurs dans les 3 catégories d’âge qui ont eu ou non une infection.


```
summary(earinf)

##      Swim      Loc      Age      Sex      NumInfec
## Freq :143  Beach  :147  15-19:140  Female: 99  Min.   : 0.000
## Occas:144  NonBeach:140  20-24: 79  Male  :188  1st Qu.: 0.000
##                                     25-29: 68  Median : 0.000
##                                     Mean   : 1.387
##                                     3rd Qu.: 2.000
##                                     Max.   :17.000
##      Infec
## Min.   :0.0000
## 1st Qu.:0.0000
## Median :0.0000
## Mean   :0.4739
## 3rd Qu.:1.0000
## Max.   :1.0000
```

```
graph1 ; graph2
```


```
## Warning: annotation$theme is not a valid theme.  
## Please use `theme()` to construct themes.
```

Proportion d'infection selon les variables explicatives - simple



```
## Warning: annotation$theme is not a valid theme.  
## Please use `theme()` to construct themes.
```

Proportion d'infection selon les variables explicatives - bivariée



Définition du modèle

La variable réponse $Y_i = Infec_i$ est une variable binaire, prenant 0 ou 1 comme valeurs. Les données alors sont sous la forme $[(Y_i, X_i), i = 1, \dots, 287]$ avec $Y_i \in \{0, 1\}$ et $(X_i = (X_{i1}, \dots, X_{i4})^T$ l'ensemble des 4 variables explicatives pour l'observation i .

Le modèle logistique s'écrit comme :

$$\log\left(\frac{\pi_i}{1 - \pi_i}\right) = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}$$

où $\pi_i = P(Y_i = 1)$ désigne la probabilité de succès pour l'observation i .

$$\pi_i = \frac{e^{\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}}}{1 + e^{\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}}}$$

```
summary(modele_initial)
```

```
##
## Call:
## glm(formula = Infec ~ Swim + Loc + Sex + Age, family = binomial(link = "logit"),
##      data = earinf)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -0.58489     0.30273  -1.932  0.05335 .
## SwimOccas    0.40464     0.24197   1.672  0.09447 .
## LocNonBeach  0.73852     0.25059   2.947  0.00321 **
## SexMale     -0.02973     0.26520  -0.112  0.91075
## Age20-24    -0.16372     0.29651  -0.552  0.58084
## Age25-29    -0.09648     0.30566  -0.316  0.75227
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 397.08  on 286  degrees of freedom
## Residual deviance: 384.93  on 281  degrees of freedom
## AIC: 396.93
##
## Number of Fisher Scoring iterations: 4
```

Sélection des variables

Cas où l'âge est catégoriel

Les méthodes de sélection de variables, forward, backward et stepwise sélectionnent les variables Swim et Loc comme étant les plus significatives dans le modèle. Voici la méthode forward à titre d'exemple ainsi que les AIC finaux des 3 méthodes.

On a le modèle suivant: $Y_i = \beta_0 + \beta_1 \text{Swim}_{Occas} + \beta_2 \text{Loc}_{NonBeach}$.

```
forward_1 <- step(modele_min_1, scope = list(lower = modele_min_1, upper = modele_max_1),
               direction = "forward", trace = TRUE)
```

```
## Start: AIC=399.08
## Infec ~ 1
##
##           Df Deviance    AIC
## + Loc      1   388.07 392.07
## + Swim      1   394.52 398.52
## <none>       397.08 399.08
## + Sex       1   396.86 400.86
## + Age       2   396.58 402.58
##
## Step: AIC=392.07
## Infec ~ Loc
##
##           Df Deviance    AIC
## + Swim      1   385.25 391.25
## <none>       388.07 392.07
## + Sex       1   388.07 394.07
## + Age       2   387.76 395.76
##
## Step: AIC=391.25
## Infec ~ Loc + Swim
##
##           Df Deviance    AIC
## <none>       385.25 391.25
## + Sex       1   385.25 393.25
## + Age       2   384.94 394.94
```

```
AIC(forward_1,backward_1,stepwise_1)
```

```
##           df      AIC
## forward_1    3 391.2532
## backward_1   3 391.2532
## stepwise_1   3 391.2532
```

Cas où l'âge est continu

L'âge initialement catégoriel, a été converti en une variable numérique en prenant l'âge moyen de chaque catégorie. En incluant la variable d'âge continue, le modèle complet obtient un AIC plus faible (395.1) que celui avec l'âge catégoriel (396.2). Le BIC également confirme le fait que le modèle avec l'âge considéré comme étant continu est le plus adapté aux données.

Incluons des termes d'interaction, cubiques, quadratiques et voyons si ces ajouts améliorent le modèle.

```
data.frame(AIC=c(AIC_1,AIC_2), BIC=c(BIC_1,BIC_2) )
```

```
##           AIC      BIC
## 1 396.9273 418.8842
## 2 395.0907 413.3881
```

Pour déterminer si l'on doit inclure des termes carrés, cubiques ou encore des interactions, considérons le modèle contenant tous ces termes. Les méthodes backward et stepwise sélectionnent les mêmes variables avec un AIC de 391.1 tandis que la méthode forward sélectionne le même modèle sans interaction avec un AIC de 391.2. Le meilleur modèle est celui avec le plus petit AIC, donc celui contenant les variables Swim, Loc, Sexe et l'interaction entre ces 2 dernières variables.

On obtient le modèle final suivant: $Y_i = \beta_0 + \beta_1 Swim_{Occas} + \beta_2 Loc_{NonBeach} + \beta_3 Sex_{Male} + \beta_4 Loc_{NonBeach} * Sex_{Male}$.

Fonction de lien

Testons les 3 fonctions de lien:

-Logit qui est définie par $g(u) = \text{logit}(u) = \log\left(\frac{u}{1-u}\right)$.

-Probit qui est définie par $g(u) = (u)$.

-C-log-log qui est définie par $g(u) = \log(-\log(1 - u))$.

Les résultats des différents modèles sont très similaires. Par conséquent, la fonction de lien n'influence pas les résultats, mais pour une meilleure interprétation, on privilégiera la fonction logit.

resultats2

##		Estimate	Std. Error	z value	Pr(> z)
##	beta0 (logit)	-0.41053576	0.2868689	-1.43109193	0.152403870
##	beta0 (probit)	-0.25464652	0.1783639	-1.42767976	0.153384054
##	beta0 (cloglog)	-0.68484569	0.2170856	-3.15472629	0.001606487
##	beta1 (logit)	0.41509704	0.2437374	1.70305005	0.088558703
##	beta1 (probit)	0.25653036	0.1507030	1.70222521	0.088713158
##	beta1 (cloglog)	0.32085984	0.1766771	1.81608099	0.069357949
##	beta2 (logit)	0.03306821	0.4192997	0.07886532	0.937139752
##	beta2 (probit)	0.02009079	0.2617178	0.07676510	0.938810414
##	beta2 (cloglog)	0.03136765	0.3126686	0.10032237	0.920088395
##	beta3 (logit)	-0.46438016	0.3444949	-1.34800319	0.177657357
##	beta3 (probit)	-0.28625259	0.2130422	-1.34364247	0.179064028
##	beta3 (cloglog)	-0.36298353	0.2685708	-1.35153760	0.176523283
##	beta4 (logit)	1.05834579	0.5195120	2.03719209	0.041630797
##	beta4 (probit)	0.65791050	0.3225476	2.03973132	0.041377094
##	beta4 (cloglog)	0.78402641	0.3876817	2.02234586	0.043140633

Interprétation du modèle

Le modèle est

$Y_i = -0.41053576 + 0.41509704 * Swim_i + 0.03306821 * Loc_i - 0.46438016 * Sex_i + 1.05834579 * Loc * Sex_i$
avec les catégories de référence Swim = Freq, Loc = Beach et Sex = Female.

On peut donc interpréter celui-ci avec e^{β_j} : Les nageurs occasionnels ont $e^{0.41509704} = 1.514$, donc le fait de nager occasionnellement plutôt que fréquemment augmente le risque d'infection de 51.4%.

Le fait de nager ailleurs qu'à la mer augmente le risque d'infection de 3.36% en comparaison au fait de nager à la mer.

Ensuite, les hommes ont une cote d'infection 0.6286 fois plus que celle des femmes.

Enfin, chez les hommes, le fait de nager ailleurs qu'à la mer a un risque $e^{1.05835+0.03307} = 2.9785$ fois plus élevé.

Valeurs influentes, aberrantes et extravariabilité

Aucune observation n'a été déclarée influente ou aberrante. Le facteur de dispersion $\$ = 1.351358 < 2$ et proche de 1, alors on peut conclure qu'il n'y a pas d'extra variabilité.

```
intersect(indices.d3,indices.d4)
```

```
## integer(0)
```

```
intersect(intersect(indices.d2,indices.d3),indices.d4)
```

```
## integer(0)
```

```
print(rapport_phi)
```

```
## [1] 1.351358
```

Validation du modèle

La déviance est une des statistiques disponible pour tester l'adéquation globale d'un modèle. $D = \sum_{i=1}^n r_{D,i}^2$ et suit approximativement une loi du $\chi^2_{n-(p+1)}$ sous l'hypothèse d'un bon ajustement.

La p-value obtenue étant très significative, l'hypothèse nulle que le modèle est adéquat aux données est rejetée.

De plus, en déterminant l'aire sous la courbe ROC, on obtient une aire de 63.3% avec une erreur-type de 0.032.


Le modèle ne prédit pas bien l'infection de l'oreille à travers ce jeu de données, il est d'ailleurs mauvais.

```
pvalue.adequation
```

```
## [1] 7.483208e-05
```

```
print(courbe.roc);plot(courbe.roc)
```

```
## ROC curve with AUC = 0.6330347 and s.e. = 0.03248327
```



```
knitr::kable(validation_results,
  caption = "Résumé des critères de validation du modèle logistique final",
  col.names = c("Critère de validation", "Résultat numérique", "Conclusion"),
  align = 'lrr')
```

```
## Warning in attr(x, "align"): 'xfun::attr()' is deprecated.
## Use 'xfun::attr2()' instead.
## See help("Deprecated")
```

```
## Warning in attr(x, "format"): 'xfun::attr()' is deprecated.
## Use 'xfun::attr2()' instead.
## See help("Deprecated")
```

Résumé des critères de validation du modèle logistique final

Critère de validation	Résultat numérique	Conclusion
Adéquation globale	7.48e-05	Très significative (Rejet de H_0 : Modèle non adéquat)
Surdispersion	1.351	1.351 (Non significative)
Pouvoir prédictif (AUC)	0.633	0.633 (Mauvaise performance)